Intro

本レポートでは、MDPGridworld-v3 に対して開発した性能の良いエージェントについて述べる。エージェントは、ActorCritic 法をベースとして、報酬の低いエピソード終了フラグをもつ状態に遷移しないよう、改良を加えたものを使用した。

手法

Q 学習と ActorCritic 法について

まず、Q 学習と ActorCritic 法のエージェントの学習方法の違いから述べる。それぞれのエージェントは状態 s の時に行動 a を行った所、報酬 r を得て状態 s' に遷移したと仮定する。また、γ は報酬の割引率である。

Q 学習では、行動価値関数 Q(s,a) の値を、ActorCritic では状態価値 V(s) と方策関数 $\pi(s,a)$ をそれぞれ以下のように更新する。

$$Q(s,a) \leftarrow Q(s,a) + \alpha\{r + \gamma \max_a Q(s',a) - Q(s,a)\}$$

$$td = r + \gamma V(s') - V(s)$$
$$V(s) \leftarrow V(s) + \alpha td \qquad \pi(s,a) \leftarrow \pi(s,a) + \beta td$$

これらの更新式はいずれも、まず、Q や V の予測誤差である時間的差分 (TD) を計算する。予測誤差をもとの関数に足し合わせて更新することにより、Q 学習や ActorCritic 法ではより正確な値を得ることができる。α, β は任意に決めれるハイ・パラメータで、更新の度合いを決定する。

次に、状態 s の時の行動選択について、Q 学習は $\arg\max_a Q(s,a)$ を選ぶ。ActorCritic 法はとれる行動が $[a_1, a_2, a_3]$ である時、$[\pi(s,a_1), \pi(s,a_2), \pi(s,a_3)]$ を softmax 関数に代入して得られた値をその行動をとる確率として選択する。

ActorCritic に加えた修正

MDPGridworld-v3 の場合、報酬が高いエピソード終了フラグをもつ状態が一つと低い報酬をもつエピソード終了フラグを持つ状態が複数ある。今後、前者を真のゴール、後者を偽のゴールと呼ぶ。このような環境下では、エージェントは偽のゴールに遷移し、総報酬が低くなる。すなわち、局所最適に陥る。これを回避するため、偽のゴール以上、真のゴール以下の値を持つ閾値 $r_{threshold}$ を設定し、$r < r_{threshold}$ の時、$td \leftarrow -1000$ と、非常に低い値を代入する。こうすることで、偽のゴールへ至ることを回避している。

Results

Q 学習と ActorCritic 法の最適パラメータの探索

エージェントを動かすにあたって、ハイ・パラメータを設定する必要がある。この設定によって、そのエージェントの性能は大きく変わりうるため、実際に総報酬が多くなるようなハイ・パラメータの探索をする必要がある。

次に、パラメータの探索範囲について述べる。Q 学習では、割引率 γ とランダムに行動選択をする確率 ϵ がそれぞれ [0.2,0.5,0.8] の値をとるとして探索を行った。α は 0.2 で固定した。一方、ActorCritic 学習では、α, β がそれぞれ [0.2,0.5,0.8] の値をとるとして探索を行った。γ は 0.95 で固定した。こうして探索した結果が、以下の図である。

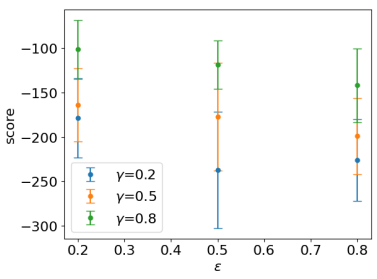


図 1　Q 学習のパラメタ探索

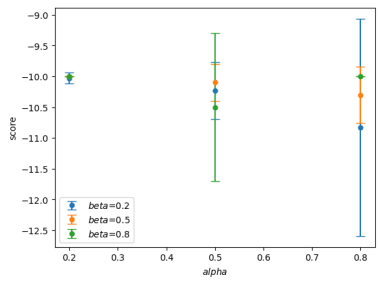


図 2　ActorCritic 法のパラメタ探索

各エージェントに 100 回のエピソードを学習させながら行わせ、最後の 10 回のエピソードの総報酬の平均と分散を求めた。この最後の 10 エピソードの平均と分散を表す。Q 学習の場合、$\epsilon = 0.2, \gamma = 0.8$ の場合が最も平均が高いので、これを最適パラメータとみなす。ActorCritic 法の場合、平均の差は小さいので分散の大きさを評価対象とする。分散が大きい、すなわち環境の探索性能が高い $\alpha = 0.8, \beta = 0.2$ を最適方策とする

Q 学習と ActorCritic 法の比較

前節で決定した最適パラメータを使ったエージェントに対し、学習を行わせた。エピソードごとのステップ数と総報酬を下図に示す。

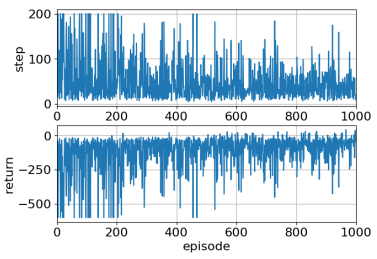


図 3　Q 学習のスコアとステップ

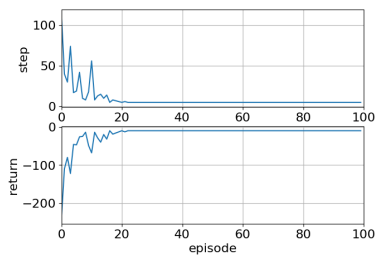


図 4　ActorCritic のスコアとステップ

ActorCritic エージェントは 20 エピソード目程度で学習が収束するのに対し、Q エージェントはいつまでたっても収束くしない。ActorCritic エージェントの方ががより良いエージェントといえる。

修正された ActorCritic 法の性能評価

前節の ActorCritic エージェントは、総報酬が-10 に収束した。この環境において、最適方策をとった場合の総報酬は 58 なので、局所最適に陥っている。修正された ActorCritic エージェントの学習の様子を以下に示す。

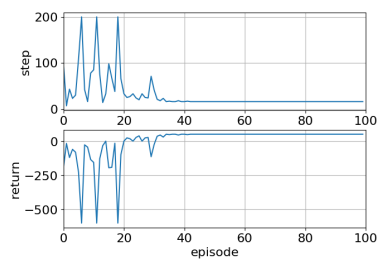


図 5　修正された ActorCritic 法

総報酬は 52 に収束した。修正を加えることで、確かに最適方策に近い方策を得ることができた。

Discussion

Q 学習エージェントは $s \times a$ 個、ActorCritic エージェントは $s \times a + s$ 個分の実数値情報を記憶している。(s: 状態の個数、a: 行動の個数) ActorCritic は Q 学習と比較し、環境に対しより多くの記憶容量を持っているため、より優れた学習性能を発揮したと考えられる。

また、ActorCritic に対する修正は、真のゴールが持つ報酬が分かっていることを前提としていた。このように環境に対する仮定を加えると、エージェントの性能はよくなることが分かる。